

# Análisis Estadístico de Datos Multivariantes (AEDM)

Juana Mari Vivo

10/11/2023

# Introducción

# Clasificación de Técnicas Estadísticas Multivariantes

- ▶ **Técnicas estadísticas multivariantes de ajuste de modelos estadísticos.**
- ▶ **Técnicas estadísticas multivariantes de reducción de datos.**
- ▶ **Técnicas estadísticas multivariantes de clasificación.**

# Notación y conceptos usuales

## Matriz de datos

Sean  $n$  individuos observados (filas) sobre  $m$  variables  $X_1, X_2, \dots, X_m$  (columnas): la *matriz de datos*  $X$  de tamaño  $n \times m$ ,

$$\begin{pmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1m} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2m} \\ x_{31} & x_{32} & x_{33} & \dots & x_{3m} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & x_{n2} & x_{n3} & \dots & x_{nm} \end{pmatrix}$$

cada  $x_{ij}$  es el valor del individuo (fila)  $i$  para la variable (columna)  $j$ .

# Notación y conceptos usuales

## Matriz de Varianzas-Covarianzas

Se trata de una matriz simétrica.

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} & \dots & \sigma_{1m} \\ \sigma_{21} & \sigma_2^2 & \sigma_{23} & \dots & \sigma_{2m} \\ \sigma_{31} & \sigma_{32} & \sigma_3^2 & \dots & \sigma_{3m} \\ \dots & \dots & \dots & \dots & \dots \\ \sigma_{m1} & \sigma_{m2} & \sigma_{m3} & \dots & \sigma_m^2 \end{pmatrix} \in M(m)$$

La varianza total de  $X$  es la suma de varianzas, es decir, la suma de los  $m$  elementos de la diagonal de la matriz de covarianzas.

# Notación y conceptos usuales

## Matriz de Correlaciones


Si las variables originales son estandarizadas, i.e.  $Z_i = \frac{X_i - \mu}{\sigma_1}$ , la matriz correspondiente se denomina matriz de correlaciones.

$$R = \begin{pmatrix} 1 & r_{12} & r_{13} & \dots & r_{1m} \\ r_{21} & 1 & r_{23} & \dots & r_{2m} \\ r_{31} & r_{32} & 1 & \dots & r_{3m} \\ \dots & \dots & \dots & \dots & \dots \\ r_{m1} & r_{m2} & r_{m3} & \dots & 1 \end{pmatrix} \in M(m)$$

$r_{ij} \in [-1, 1]$ : la relación entre cada par de variables (inversa o directa) y su grado (más fuerte cuanto más próximo a -1 y a 1, pero más débil cuanto más próximo a 0). Nótese que la varianza total es igual a  $m$ , i.e., igual al número de variables.

# Notación y conceptos usuales

## Distribución normal bivalente



# Análisis de Componentes Principales



# Introducción

El análisis de componentes principales (ACP) es una técnica estadística de análisis multivariante, introducida a finales del siglo XIX por Pearson y estudiada por Hotelling en la primera mitad del siglo XX.

- ▶ Adecuación: Se aplica cuando se dispone de un número elevado de variables cuantitativas *intercorrelacionadas*.
- ▶ Eliminación de redundancia en la información: Consiste en sustituir las  $m$  variables originales por  $k$  combinaciones lineales de las mismas no directamente observables, denominadas *componentes principales incorreladas entre sí* y pueden ordenarse de acuerdo a su varianza asociada (información de la componente).
- ▶ Reducción de dimensiones:  $k$  debe ser menor que  $m$ , pero expresando una proporción razonable de la variación total (*inercia de la nube de puntos*) cuantificada como la traza de la matriz de varianzas-covarianzas,  $tr(\Sigma)$ .

## Detrás del ACP

- ▶ En relación a los individuos ¿Hay similitudes entre los individuos para todas las variables? ¿Podemos establecer diferentes perfiles de individuos? ¿Podemos oponer a un grupo de individuos a otro?
- ▶ En relación a las variables ¿Podemos resumir las características por un pequeño número de variables?
- ▶ En relación a ambos ¿Podemos caracterizar grupos de individuos por variables?

# Obtención de las componentes principales

Si se considera  $n$  individuos observados sobre  $m$  variables originales  $X_1, X_2, \dots, X_m$  e  $Y_1, Y_2, \dots, Y_m$  las componentes principales:

$$Y_j = a_{j1}X_1 + a_{j2}X_2 + \dots + a_{jm}X_m = a'_j X$$

con  $a'_j = (a_{j1}, a_{j2}, \dots, a_{jm})$  es un vector con componentes constantes tal que  $a'_j a_j = 1$  (condición de ortogonalidad),  $j = 1, 2, \dots, m$ .

- La primera componente se calcula tomando  $a_1$  tal que  $Y_1$  tenga la mayor varianza posible,  $Var(Y_1) = Var(a'_1 X) = a'_1 \Sigma a_1$  sujeta a la restricción de que  $a'_1 a_1 = 1$ , a través del método de los multiplicadores de Lagrange:  $L(a_1) = a'_1 \Sigma a_1 - \lambda(a'_1 a_1 - 1)$

$$\frac{\partial L}{\partial a_1}(a_1) = 2\Sigma a_1 - 2\lambda/a_1 \Rightarrow (\Sigma - \lambda I)a_1 = 0$$

# Obtención de las componentes principales

Para que el sistema  $(\Sigma - \lambda I)a_1 = 0$  tenga solución distinta de cero (Th. Rouché-Frobenius)  $\Rightarrow |\Sigma - \lambda I| = 0$

$$\text{Var}(Y_1) = \text{Var}(a_1'X) = a_1'\Sigma a_1 = a_1'\lambda a_1 = \lambda a_1'a_1 = \lambda$$

Por tanto, para maximizar la varianza de  $Y_1$  se tiene que tomar el mayor autovalor,  $\lambda_1$  y el correspondiente autovector  $a_1$ .

- ▶ La segunda componente principal se calcula obteniendo  $a_2$  de modo que la variable obtenida,  $Y_2$  esté incorrelada con  $Y_1$ , i.e,  $\text{Cov}(Y_1, Y_2) = \text{Cov}(a_1'X_1, a_2'X_2) = a_2'\Sigma a_1 = \lambda a_2'a_1 = 0$  y razonando de manera similar, elegimos  $\lambda_2$  como el segundo mayor autovalor de la matriz  $\Sigma$  con su autovector asociado  $a_2$ , a través de la función:

$$L(a_2) = a_2'\Sigma a_2 - \lambda(a_2'a_2 - 1) - \delta a_2'a_1$$

# Obtención de las componentes principales

- ▶ Análogamente, se obtiene  $Y_3, \dots, Y_m$ , en orden decreciente de varianza.

Por tanto, las  $m$  componentes  $Y$  se pueden expresar como el producto de una matriz formada por los autovectores  $A$ , multiplicada por el vector  $X$  que contiene las variables originales  $X_1, \dots, X_m$ , i.e.,  $Y = AX$ . La matriz de varianzas-covarianzas viene dada por:

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m) = \text{Var}(Y) = A' \text{Var}(X) A = A' \Sigma A$$

## Porcentajes de variabilidad

Dado que  $\lambda_i = \text{Var}(Y_i)$  correspondiente al autovector  $a_i$ , entonces la varianza total de las componentes es la suma de todos los autovalores:

$$\sum_{i=1}^m \text{Var}(Y_i) = \sum_{i=1}^m \lambda_i = \text{tr}(\Lambda)$$

$$\text{tr}(\Lambda) = \text{tr}(A'\Sigma A) = \text{tr}(\Sigma A' A) = \text{tr}(\Sigma)$$

Por tanto, la suma de las varianzas de las variables originales y la suma de las varianzas de las componentes son iguales.

# Porcentajes de variabilidad

- ▶ El porcentaje de varianza total que retiene una componente principal:

$$\frac{\lambda_i}{\sum_{i=1}^m \lambda_i} = \frac{\lambda_i}{\sum_{i=1}^m \text{Var}(X_i)}$$

- ▶ El porcentaje de variabilidad retenido por las primeras  $k$  componentes:

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^m \lambda_i}$$


con  $k < m$ .

## Caso práctico

Anderson recopiló estos datos para cuantificar la variación morfológica de las flores de Iris de tres especies relacionadas.



A partir de las cuatro características medidas por Fisher (longitudes y amplitud de pétalo y sépalo, en cm)



aplicaremos un ACP.



# Caso práctico

```
> data(iris) #cargando datos  
> names(iris)
```

```
[1] "Sepal.Length" "Sepal.Width"  "Petal.Length" "Petal.Width"  "Species"
```

```
> names(iris)[c(1,2,3,4)] <- c("SLength","SWidth","PLength","PWidth")  
> names(iris)
```

```
[1] "SLength" "SWidth"  "PLength" "PWidth"  "Species"
```

## Caso práctico

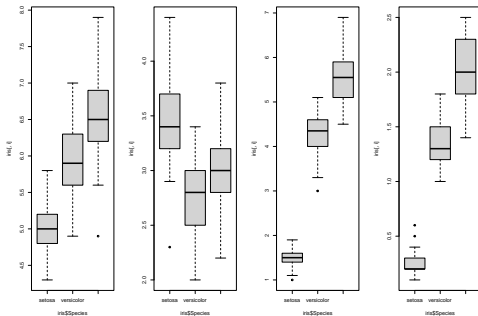
```
>
> tapply(iris[,1],iris$Species,summary)
$setosa
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
4.300  4.800   5.000   5.006  5.200   5.800

$versicolor
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
4.900  5.600   5.900   5.936  6.300   7.000

$virginica
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
4.900  6.225   6.500   6.588  6.900   7.900
```


# Caso práctico

```
> par(mfrow=c(1,4))  
> for (i in 1:4) boxplot(iris[,i]~iris$Species)
```




## Caso práctico

```
> par(mfrow=c(1,1))  
> boxplot(iris[,1:4],col="bisque",outcol=3,outpch = 15)
```



# Caso práctico

```
> library(scatterplot3d)
> scatterplot3d(iris[,1], iris[,2],iris[,3], color=as.numeric(iris[,5]),pch=as.numeric(iris[,5]))
```



# Caso práctico


```
> require(car)
```

Loading required package: car

Loading required package: carData

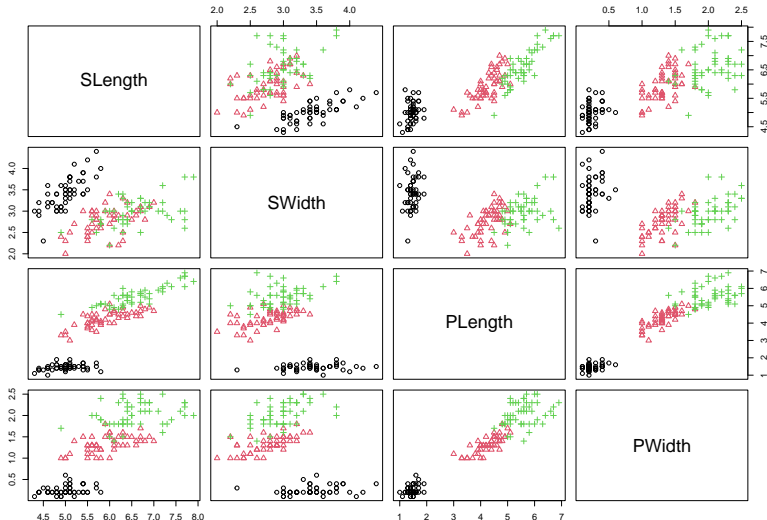
```
> par(mfrow=c(1,4))
```

```
> for (i in 1:4){qqPlot(iris[,i],pch=20)}
```



# Caso práctico

```
> pairs(iris[,1:4], pch=as.numeric(iris[,5]), col=iris[,5])
```



## Caso práctico

```
> round(cov(iris[,1:4]),2)
```

	SLength	SWidth	PLength	PWidth
SLength	0.69	-0.04	1.27	0.52
SWidth	-0.04	0.19	-0.33	-0.12
PLength	1.27	-0.33	3.12	1.30
PWidth	0.52	-0.12	1.30	0.58


```
> round(cor(iris[,1:4]),2)
```

	SLength	SWidth	PLength	PWidth
SLength	1.00	-0.12	0.87	0.82
SWidth	-0.12	1.00	-0.43	-0.37
PLength	0.87	-0.43	1.00	0.96
PWidth	0.82	-0.37	0.96	1.00




# Caso práctico

```
> library(corr)
> cor <- correlate(iris[,1:4])
> network_plot(cor)
```



# Caso práctico

```
> library(corrplot)
> corrplot.mixed(cor(iris[,1:4]),lower.col =1)
```



<https://cran.r-project.org/web/packages/corrplot/vignettes/corrplot-intro.html>

## Caso práctico: Idoneidad del ACP

- Test de Esfericidad de Bartlett

$$\begin{cases} H_0 & : |R| = 1 \\ H_1 & : |R| \neq 1 \end{cases}$$

$$T = -(n - 1 - \frac{2m + 5}{6}) \ln |R| \sim \chi^2_{m(m-1)/2}$$

## Caso práctico

```
> library("psych")  
> cortest.bartlett(cor(iris[,1:4]), n = 150)
```

```
$chisq  
[1] 706.9592
```

```
$p.value  
[1] 1.92268e-149
```

```
$df  
[1] 6
```

## Caso práctico

```
> library("REdaS")  
> bart_spher(iris[,1:4])
```

Bartlett's Test of Sphericity

Call: bart\_spher(x = iris[, 1:4])

X2 = 706.959

df = 6

p-value < 2.22e-16

# Caso práctico: Idoneidad del ACP

- Medida de la adecuación muestral de Kaiser-Meyer-Olkin (KMO)

$$KMO = \frac{\sum_i \sum_{j \neq i} r_{ij}^2}{\sum_i \sum_{j \neq i} r_{ij}^2 + \sum_i \sum_{j \neq i} a_{ij}^2}$$

KMO Value	Degree of Common Variance
0.90 to 1.00	Marvelous
0.80 to 0.89	Meritorious
0.70 to 0.79	Middling
0.60 to 0.69	Mediocre
0.50 to 0.59	Miserable
0.00 to 0.49	Don't Factor or unacceptable

Bartlett's Test of Sphericity and the Kaiser-Meyer-Olkin Test of Sampling Adequacy (KMO) are commonly used to provide more complex measures for assessing the strength of the relationships and suggesting factorability of the variables (Beavers et al., 2013). Kaiser (1974) recommends that the accepted index of KMO & Bartlett's Test of Sphericity should be over 0.5. Also, the Bartlett's Test of Sphericity relates to the significance of the study and thereby

## Caso práctico

```
> KMO(iris[,1:4])
```

Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = iris[, 1:4])

Overall MSA = 0.54

MSA for each item =

SLength	SWidth	PLength	PWidth
0.58	0.27	0.53	0.63

## Caso práctico

```
> KMOS(iris[,1:4])
```

Kaiser-Meyer-Olkin Statistics

Call: KMOS(x = iris[, 1:4])

Measures of Sampling Adequacy (MSA):



SLength	SWidth	PLength	PWidth
0.5840603	0.2695746	0.5307484	0.6342065

KMO-Criterion: 0.5400767




# Caso práctico

```
> library(FactoMineR)
> iris.pca=PCA(iris[,1:4], scale.unit=T, ncp=4, graph=T)
```



# Caso práctico

```
> barplot(iris.pca$eig[,1],main="Eigenvalues",names.arg=1:nrow(iris.pca$eig))
```



# Caso práctico

```
> options(width = 300)
> summary.PCA(iris.pca)
```

Call:

```
PCA(X = iris[, 1:4], scale.unit = T, ncp = 4, graph = T)
```

Eigenvalues

	Dim.1	Dim.2	Dim.3	Dim.4
Variance	2.918	0.914	0.147	0.021
% of var.	72.962	22.851	3.669	0.518
Cumulative % of var.	72.962	95.813	99.482	100.000

Individuals (the 10 first)


	Dist	Dim.1	ctr	cos2	Dim.2	ctr	cos2	Dim.3	ctr	cos2
1	2.319	-2.265	1.172	0.954	0.480	0.168	0.043	-0.128	0.074	0.003
2	2.202	-2.081	0.989	0.893	-0.674	0.331	0.094	-0.235	0.250	0.011
3	2.389	-2.364	1.277	0.979	-0.342	0.085	0.020	0.044	0.009	0.000
4	2.378	-2.299	1.208	0.935	-0.597	0.260	0.063	0.091	0.038	0.001
5	2.476	-2.390	1.305	0.932	0.647	0.305	0.068	0.016	0.001	0.000
6	2.555	-2.076	0.984	0.660	1.489	1.617	0.340	0.027	0.003	0.000
7	2.468	-2.444	1.364	0.981	0.048	0.002	0.000	0.335	0.511	0.018
8	2.246	-2.233	1.139	0.988	0.223	0.036	0.010	-0.089	0.036	0.002
9	2.592	-2.335	1.245	0.812	-1.115	0.907	0.185	0.145	0.096	0.003
10	2.249	-2.184	1.090	0.943	-0.469	0.160	0.043	-0.254	0.293	0.013

Variables

	Dim.1	ctr	cos2	Dim.2	ctr	cos2	Dim.3	ctr	cos2
SLength	0.890	27.151	0.792	0.361	14.244	0.130	-0.276	51.778	0.076
SWidth	-0.460	7.255	0.212	0.883	85.247	0.779	0.094	5.972	0.009
PLength	0.992	33.688	0.983	0.023	0.060	0.001	0.054	2.020	0.003
PWidth	0.965	31.906	0.931	0.064	0.448	0.004	0.243	40.230	0.059

# Caso práctico: Scree plot

```
> library(factoextra)
> fviz_screplot(iris.pca, addlabels = TRUE, ylim = c(0, 75))
```



# Caso práctico

```
> names(iris.pca)
```

```
[1] "eig"  "var"  "ind"  "svd"  "call"
```

# Caso práctico

```
> print(iris.pca)
```

```
**Results for the Principal Component Analysis (PCA)**
```

```
The analysis was performed on 150 individuals, described by 4 variables
```

```
*The results are available in the following objects:
```

	name	description
1	"\$eig"	"eigenvalues"
2	"\$var"	"results for the variables"
3	"\$var\$coord"	"coord. for the variables"
4	"\$var\$cor"	"correlations variables - dimensions"
5	"\$var\$cos2"	"cos2 for the variables"
6	"\$var\$contrib"	"contributions of the variables"
7	"\$ind"	"results for the individuals"
8	"\$ind\$coord"	"coord. for the individuals"
9	"\$ind\$cos2"	"cos2 for the individuals"
10	"\$ind\$contrib"	"contributions of the individuals"
11	"\$call"	"summary statistics"
12	"\$call\$centre"	"mean of the variables"
13	"\$call\$ecart.type"	"standard error of the variables"
14	"\$call\$row.w"	"weights for the individuals"
15	"\$call\$col.w"	"weights for the variables"

# Caso práctico

```
> iris.pca$eig
```

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.91849782	72.9624454	72.96245
comp 2	0.91403047	22.8507618	95.81321
comp 3	0.14675688	3.6689219	99.48213
comp 4	0.02071484	0.5178709	100.00000

# Caso práctico

## loading (vectores propios asociados al valor propio)

```
> iris.pca$svd$V
```

	[,1]	[,2]	[,3]	[,4]
[1,]	0.5210659	0.37741762	-0.7195664	-0.2612863
[2,]	-0.2693474	0.92329566	0.2443818	0.1235096
[3,]	0.5804131	0.02449161	0.1421264	0.8014492
[4,]	0.5648565	0.06694199	0.6342727	-0.5235971

$$Y_1 = 0.52 * Sepal.Length - 0.27 * Sepal.Width + 0.58 * Petal.Length + 0.56 * Petal.Width$$

$$Y_2 = 0.38 * Sepal.Length + 0.92 * Sepal.Width + 0.02 * Petal.Length + 0.07 * Petal.Width$$

```
> (iris.pca$var$coord) #Coordenadas de las variables en las componentes principales
```

	Dim.1	Dim.2	Dim.3	Dim.4
SLength	0.8901688	0.36082989	-0.27565767	-0.03760602
SWidth	-0.4601427	0.88271627	0.09361987	0.01777631
PLength	0.9915552	0.02341519	0.05444699	0.11534978
PWidth	0.9649790	0.06399985	0.24298265	-0.07535950



# Caso práctico

```
> iris.pca$var$cor
```

	Dim.1	Dim.2	Dim.3	Dim.4
SLength	0.8901688	0.36082989	-0.27565767	-0.03760602
SWidth	-0.4601427	0.88271627	0.09361987	0.01777631
PLength	0.9915552	0.02341519	0.05444699	0.11534978
PWidth	0.9649790	0.06399985	0.24298265	-0.07535950

```
> cor(iris$SLength, iris.pca$ind$coord ) #Correlación entre las variables y las componentes
```

	Dim.1	Dim.2	Dim.3	Dim.4
[1,]	0.8901688	0.3608299	-0.2756577	-0.03760602

# Caso práctico

Calidad de representación de cada variable sobre los ejes  
Cosenos al cuadrado y su acumulación para los factores  
retenidos es la comunalidad

```
> iris.pca$var$cos2
```

	Dim.1	Dim.2	Dim.3	Dim.4
SLength	0.7924004	0.130198208	0.075987149	0.0014142127
SWidth	0.2117313	0.779188012	0.008764681	0.0003159971
PLength	0.9831817	0.000548271	0.002964475	0.0133055723
PWidth	0.9311844	0.004095980	0.059040571	0.0056790544

```
> rowSums(iris.pca$var$cos2)
```

SLength	SWidth	PLength	PWidth
1	1	1	1

# Caso práctico

## Contribuciones de cada variable sobre los componentes principales

```
> iris.pca$var$contrib
```

	Dim.1	Dim.2	Dim.3	Dim.4
SLength	27.150969	14.24440565	51.777574	6.827052
SWidth	7.254804	85.24748749	5.972245	1.525463
PLength	33.687936	0.05998389	2.019990	64.232089
PWidth	31.906291	0.44812296	40.230191	27.415396

```
> colSums(iris.pca$var$contrib)
```

Dim.1	Dim.2	Dim.3	Dim.4
100	100	100	100

# Caso práctico

## Valores propios

```
> iris.pca$eig
```

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.91849782	72.9624454	72.96245
comp 2	0.91403047	22.8507618	95.81321
comp 3	0.14675688	3.6689219	99.48213
comp 4	0.02071484	0.5178709	100.00000

# Caso práctico

## Distancias de los individuos al centro de gravedad de la nube de puntos

```
> iris.pca$ind$dist
```

1	2	3	4	5	6	7	8	9	10	
2.3186628	2.2023867	2.3894014	2.3783885	2.4761421	2.5547337	2.4676790	2.2458571	2.5915769	2.2488335	2.4196152
31	32	33	34	35	36	37	38	39	40	41
2.2005982	1.9144052	3.1795671	3.2586152	2.1664754	2.2352302	2.2121517	2.5994670	2.5996342	2.1933821	2.3314061
61	62	63	64	65	66	67	68	69	70	71
2.6568072	0.4918154	2.0046733	0.7644111	0.4936869	1.1357908	0.6624551	0.8865720	2.1014703	1.3253442	1.0432891
91	92	93	94	95	96	97	98	99	100	101
1.1893408	0.6426036	1.0630118	2.0542832	0.9188165	0.3327074	0.4919403	0.6560470	1.6309294	0.6606152	2.2744061
121	122	123	124	125	126	127	128	129	130	131
2.2504615	1.4035404	3.0526824	1.4245238	2.0033487	2.2492371	1.2302797	1.0773149	1.8186594	2.0844277	2.5556152

# Caso práctico

## Coordenadas de los individuos

```
> head(round(iris.pca$ind$coord,2))
```

	Dim.1	Dim.2	Dim.3	Dim.4
1	-2.26	0.48	-0.13	-0.02
2	-2.08	-0.67	-0.23	-0.10
3	-2.36	-0.34	0.04	-0.03
4	-2.30	-0.60	0.09	0.07
5	-2.39	0.65	0.02	0.04
6	-2.08	1.49	0.03	-0.01

## Caso práctico

Calidad de representación de cada individuo en los ejes

```
> head(iris.pca$ind$cos2)
```

	Dim.1	Dim.2	Dim.3	Dim.4
1	0.9539975	0.04286032	0.0030335249	1.086460e-04
2	0.8927725	0.09369248	0.0113475382	2.187482e-03
3	0.9790410	0.02047578	0.0003422122	1.410446e-04
4	0.9346682	0.06308947	0.0014732682	7.690193e-04
5	0.9315095	0.06823959	0.0000403979	2.104697e-04
6	0.6600989	0.33978301	0.0001114335	6.690714e-06

```
> rowSums(iris.pca$ind$cos2)
```

[illegible]

# Caso práctico

```
> head(iris.pca$ind$contrib) # Contribuciones de cada uno de los individuos a los ejes
```

	Dim.1	Dim.2	Dim.3	Dim.4
1	1.1715796	0.16806554	0.074085470	0.018798188
2	0.9891845	0.33146674	0.250034006	0.341474919
3	1.2768164	0.08526419	0.008875320	0.025915633
4	1.2077372	0.26029781	0.037858004	0.140000650
5	1.3046313	0.30516562	0.001125175	0.041530572
6	0.9841236	1.61748779	0.003303827	0.001405371


```
> colSums(iris.pca$ind$contrib) #Observación!!!
```

Dim.1	Dim.2	Dim.3	Dim.4
100	100	100	100



## Caso práctico

```
> biplot(iris.pca$ind$coord[,1:2],iris.pca$var$coord[,1:2],xlim=c(-4,4), cex = 0.7)
```



# Caso práctico

```
> dimdesc(iris.pca, axes=c(1,2))
```

\$Dim.1

Link between the variable and the continuous variables (R-square)

```
=====
```

	correlation	p.value
PLength	0.9915552	3.369916e-133
PWidth	0.9649790	6.609632e-88
SLength	0.8901688	2.190813e-52
SWidth	-0.4601427	3.139724e-09

\$Dim.2



Link between the variable and the continuous variables (R-square)

```
=====
```

	correlation	p.value
SWidth	0.8827163	2.123801e-50
SLength	0.3608299	5.731933e-06

# Caso práctico

```
> iris.pca=PCA(iris, scale.unit=T, ncp=5, graph=T, quali.sup=5)
```



# Caso práctico

```
> iris.pca$quali.sup
```

# Caso práctico

```
> iris.pca$quali.sup
```

\$coord

	Dim.1	Dim.2	Dim.3	Dim.4
setosa	-2.224753	0.2889275	-0.04283910	-0.01834076
versicolor	0.496448	-0.5501705	-0.09612951	0.03034009
virginica	1.728305	0.2612430	0.13896861	-0.01199933

\$cos2

	Dim.1	Dim.2	Dim.3	Dim.4
setosa	0.9829895	0.01657917	0.0003644734	6.680665e-05
versicolor	0.4406515	0.54118069	0.0165219448	1.645816e-03
virginica	0.9714759	0.02219630	0.0062809398	4.682797e-05

\$v.test

	Dim.1	Dim.2	Dim.3	Dim.4
setosa	-11.240362	2.608475	-0.9652043	-1.0999036
versicolor	2.508258	-4.967011	-2.1658862	1.8195091
virginica	8.732103	2.358536	3.1310905	-0.7196055

\$dist

	setosa	versicolor	virginica
	2.2439201	0.7478701	1.7534945

\$eta2

	Dim.1	Dim.2	Dim.3	Dim.4
Species	0.9346162	0.1657182	0.06902197	0.02254243

# Caso práctico

## Determinación del número de factores para extraer

```
> library(nFactors)
> ev <- eigen(cor(iris[,1:4]))
> ev

eigen() decomposition
$values
[1] 2.91849782 0.91403047 0.14675688 0.02071484

$vectors
      [,1]      [,2]      [,3]      [,4]
[1,] 0.5210659 -0.37741762 0.7195664 0.2612863
[2,] -0.2693474 -0.92329566 -0.2443818 -0.1235096
[3,] 0.5804131 -0.02449161 -0.1421264 -0.8014492
[4,] 0.5648565 -0.06694199 -0.6342727 0.5235971
```

# Caso práctico


## Determinación del número de factores para extraer

```
> ap <- parallel(subject=nrow(iris[,1:4]),var=ncol(iris[,1:4]),rep=100,cent=.95)
> nS <- nScree(ev$values,ap$eigen$gevpea)
> vp <- min(nS$Components)+1;vp
```

```
[1] 3
```

# Case practice

```
> op <- par(mfrow=c(1,2))  
> plot.PCA(iris.pca,axes=c(1,2), choix="ind", habillage=5)
```



```
> plotellipses(iris.pca,keepvar=5)
```

